

Домашнее задание по курсу «Машинное обучение в экономике»
2025–2026

Тема: «Влияние подписки на стриминговый сервис на недосып»

Выполнили:

Гузева Екатерина Андреевна, группа: БЭК238
Писарева Анастасия Сергеевна, группа: БЭК237
Стефанюк София Александровна, группа: 23БМББЭ1

Семинаристы: Погорелова П.В., Атласов А.А.

Москва, 2026

Содержание

1	Обоснование темы	2
2	Генерация и предварительная обработка данных	5
3	Классификация	10
4	Регрессия	22
5	Эффекты воздействия	26

1 Обоснование темы

Задание 1.1. Придумайте **непрерывную** зависимую (целевую) переменную и эндогенную **бинарную** переменную воздействия. Обоснуйте, почему переменная воздействия может быть эндогенной, и в соответствии с обоснованием создайте хотя бы одну дополнительную **ненаблюдаемую** переменную, которая коррелирует и с целевой переменной, и с переменной воздействия.

Ответ.

Зависимая (целевая) переменная – средняя продолжительность сна в сутки за неделю.

Эндогенная бинарная переменная воздействия – наличие подписки на стриминговый сервис.

Бинарная переменная воздействия может быть эндогенной, потому что пользователь осознанно приобретает подписку. На это решение влияют факторы, которые также влияют и на сон, однако при этом не являются наблюдаемыми.

Мы вводим две такие переменные:

1. Вечерний хронотип («сова»).

Люди с вечерним хронотипом склонны к активному досугу в позднее время (в том числе к использованию стриминговых сервисов), что повышает вероятность приобретения подписки. В то же время поздний отбой мешает человеку жить в соответствии с принятым расписанием, что порождает хронический недосып.

В статье [7] говорится, что у людей с более высоким ежедневным экранным временем ухудшается качество сна и уменьшается его продолжительность. Причем этот эффект более явно выражен у сов.

2. Самоконтроль / дисциплина сна.

Самоконтроль и дисциплина – это способность человека управлять своим поведением и действиями несмотря на соблазны. При низком самоконтроле часто возникает желание прокрастинировать перед сном лежа или посмотреть пару серий сериала. Авторы статьи [3] утверждают, что люди с более низкими показателями самоконтроля позднее ложатся спать из-за прокрастинации. Таким образом, низкий самоконтроль увеличивает вероятность наличия подписки и снижает количество часов сна.

Задание 1.2. Опишите, для чего может быть полезно изучение влияния переменной воздействия на зависимую переменную. В частности, укажите, как эта информация может быть использована бизнесом или государственными органами.

Ответ.

С каждым днем в мире становится все больше и больше вариантов для думскроллинга, все больше выпускается фильмов и сериалов, все больше площадок для их просмотра. Потребление цифрового контента влияет на качество сна, и изучение этого влияния может быть полезно для разных сегментов.

Согласно исследованиям, недостаточное количество часов сна приводит к значительным потерям ВВП и снижению производительности труда. Только в США экономические потери оцениваются в диапазоне от 280 до 411 млрд долларов в год, что соответствует

2,28% ВВП страны, а количество потерянных человеко-дней превышает 1,2 млн в год (по всей рабочей силе).

Бизнес также сталкивается с потерями из-за недостатка сна сотрудников. Во-первых, компании несут расходы на медицинскую помощь сотрудникам в рамках программ ДМС. Во-вторых, снижается производительность труда и увеличивается количество ошибок работников, растет число несчастных случаев.

В связи с этими потерями работодатели стали внедрять корпоративные программы по улучшению сна. Обзор ряда различных таких программ [5] показал, что качество и продолжительность сна работника можно улучшить, тем самым повысить его эффективность на рабочем месте.

Таким образом, если стриминговые сервисы действительно оказывают значимое влияние на сокращение сна, то это может отражаться на деятельности бизнеса и, как следствие, на благосостоянии экономики государства в целом.

Задание 1.3. Обоснуйте наличие причинно-следственной связи между зависимой переменной и переменной воздействия. Кратко опишите результаты не менее 2 предшествующих исследований из научной литературы? подкрепляющих ваши предположения. Критически оцените методологию этих работ и объясните, в чем преимущества и недостатки ваших методов по сравнению с теми, что использовались в этих исследованиях.

Ответ.

Наличие подписки на стриминговый сервис может иметь причинно-следственную связь с продолжительностью сна через механизм вытеснения времени отдыха. Доступ к большому объему контента (сериалы, фильмы, шоу) повышает привлекательность вечернего досуга перед экраном и побуждает откладывать отход ко сну ради продолжения просмотра (эффект “ну еще одна серия и точно спать”). В результате фактическое время засыпания сдвигается, при этом время подъема не изменяется, так как в основном люди просыпаются рано, чтобы поехать на работу. Это напрямую сокращает суточную продолжительность сна. Таким образом, переменная воздействия (подписка) влияет на целевую переменную (сон) следующим образом: увеличение экранного времени в вечерние часы смещает время отхода ко сну, чем уменьшает продолжительность сна.

Это предположение подкрепляется результатами предшествующих исследований.

Exelmans и Van den Bulck [2] одними из первых исследовали связь так называемого запойного просмотра (binge-watching) со сном на выборке из 423 человек в возрасте 18-25 лет. Более 80% участников отнесли себя к зрителям, склонным к запойному просмотру. Авторы обнаружили, что те, кто часто по вечерам залипают в сериалах, хуже спят, больше устают и чаще страдают от бессонницы. Самым важным фактором этих последствий является возбуждение мозга перед отходом ко сну. Захватывающий сюжет сериалов удерживает внимание зрителя, из-за чего тот дольше засыпает.

Alfonsi и соавторы [1] рассмотрели смежный механизм связи контента со сном у людей с плохим качеством сна. Авторы вводят понятие, которое переводится как “проблемный просмотр”, что означает тот просмотр, который формирует зависимость от контента и начинает уже вредить человеку. Результаты исследования показали, что чувство одиночества и дневная сонливость играют ключевую роль в формировании проблемного просмотра. Получается следующий порочный круг: из-за плохого сна мозг хуже справляется с эмоциями, а это, в свою очередь, усиливает склонность к избыточному просмотру контента в позднее время, что еще больше ухудшает сон. Применительно к нашей задаче это означает, что влияние стриминговой подписки на сон может усиливаться через эмоциональные механизмы и приобретать самоподдерживающийся характер.

Обе работы опираются на разовые опросы. Они показывают, что показатели связаны между собой, но не доказывают, что одно является причиной другого. Из этих данных

неясно, что на что влияет. Может быть наоборот, плохой сон сам по себе усиливает желание полистать ленту или посмотреть сериал перед сном. (на что косвенно указывает порочный круг у [1]). Главное же ограничение в том, что ключевые ненаблюдаемые переменные - хронотип и самоконтроль - не контролируются, поэтому оцениваемая связь смешивает эффект подписки с систематическими различиями между активными и неактивными зрителями.

Наш подход устраняет именно эти слабые места. Использование симулированных данных с заранее известным процессом генерации позволяет точно рассчитать истинные значения эффектов (ATE, LATE и CATE). Это дает возможность проверить каждую оценку на наличие смещения, что невозможно при работе с реальными наблюдательными данными. Эндогенность подписки мы моделируем явно через ненаблюдаемые хронотип и самоконтроль и нейтрализуем ее инструментальной переменной. Гибкие спецификации и методы двойного машинного обучения обеспечивают одновременный контроль множества переменных и выявляют нелинейные эффекты, которые упускаются при простом корреляционном анализе.

Однако платой за строгую идентификацию эффектов становится ограниченная внешняя валидность. Полученные выводы справедливы лишь в рамках заданного процесса генерации данных. В то же время опросные методы, несмотря на все присущие им смещения, позволяют исследовать поведение реальных людей в естественных условиях. Кроме того, LATE идентифицирует эффект только для compliers, поэтому перенос оценки на всю популяцию требует осторожности.

Задание 1.4. Придумайте хотя бы 3 контрольные переменные, по крайней мере одна из которых должна быть бинарной и хотя бы одна - непрерывной. Кратко обоснуйте выбор каждой из них.

Ответ.

X1 – возраст (непрерывная, лет)

С возрастом меняется структура и продолжительность сна — организму требуется меньше времени на восстановление, а сон становится поверхностным и прерывистым.

X2 – наличие детей (бинарная)

Наличие детей сокращает продолжительность сна (за счет ночных пробуждений и ранних подъемов) и одновременно увеличивает вероятность наличия стриминговых подписок (семейные тарифы, детский режим).

X3 – рабочие/учебные часы в неделю (непрерывная)

Высокая занятость сокращает свободное вечернее время, тем самым уменьшая продолжительность сна и ограничивая просмотр на стримингах.

X4 – пол (бинарная)

Согласно исследованиям [4], женщинам требуется больше часов сна для восстановления организма.

X5 – проживание в одиночестве (бинарная)

Люди, проживающие в одиночестве, не подвергаются пробуждениям по вине партнера, что улучшает качество их сна. Также одиночество повышает вероятность приобретения подписки на стриминг, так как это заменяет социальные вечерние активности.

X6 – доход (непрерывная, руб/мес)

Высокий доход позволяет безболезненно приобретать подписки.

X7 – физическая активность (непрерывная, ч/нед) Связь активности со сном имеет квадратичную форму, поскольку, согласно [6], умеренные нагрузки увеличивают продолжительность сна, а чрезмерные (более 25.7 ч/нед), наоборот, сокращают.

Задание 1.5. Придумайте бинарную инструментальную переменную и обоснуйте, почему она удовлетворяет необходимым условиям.

Ответ.

Инструментальная переменная - промо-подписка оператора связи (1 - подписка подключена автоматически)

Релевантность: наличие промо-подписки снижает порог входа до нуля, так как пользователь получает доступ к стримингу без необходимости самостоятельно принимать решение.

Экзогенность: тарифный план и предложение промо-подписки не связано с продолжительностью сна пользователя; промо-акции операторов связи распределяются по маркетинговым соображениям в зависимости от региона и тарифного плана. Эти факторы не связаны с хромотипом пользователя или его самоконтролем.

Монотонность: бесплатный доступ к подписке не снижает желание пользоваться стримингом, то есть среди пользователей нет тех, кто отказался бы от подписки, будь она бесплатной.

Задание 1.6. В случае необходимости приведите дополнительные содержательные комментарии о целях, задачах, методологии и вкладе вашего исследования.

Ответ.

2 Генерация и предварительная обработка данных

Задание 2.1. Опишите математически предполагаемый процесс генерации данных:

- Опишите распределения экзогенных переменных (контрольные переменные, инструмент, ненаблюдаемые факторы) с конкретными параметрами.
- Запишите потенциальные исходы переменной воздействия в зависимости от значения инструмента. Опишите, как они связаны с наблюдаемыми значениями переменной воздействия. Обоснуйте предполагаемые направления связей переменной воздействия с контрольными переменными, ненаблюдаемыми переменными и инструментом.
- Запишите потенциальные исходы зависимой переменной в зависимости от наличия воздействия. Опишите как они связаны с наблюдаемыми значениями зависимой переменной. Обоснуйте предполагаемые направления связей между зависимой переменной и остальными факторами.

Примечание: оценивается оригинальность предложенного вами процесса, поэтому, в частности, не рекомендуется использовать совсем простые линейные модели.

Ответ.

Для генерации контрольных переменных $X_1 - X_6$ использовалась библиотека "numpy" а для генерации X_7 - библиотека "scipy.stats"

1. Описание генерации контрольных переменных

- **Возраст** (X_1) определен нормальным распределением со средним значением 35 лет (средний возраст экономически активного населения) и стандартным отклонением 12 лет. Дополнительно мы ограничили диапазон возраста людей, включив туда людей от 16 до 70 лет (исключаем из выборки детей и предполагаем, что пенсионеры старше 70 редко являются активными пользователями стриминг-платформ).

Таблица 1: Контрольные переменные

Переменная	Распределение
Возраст	$X_1 \sim \mathcal{N}(35, 12^2)$, $X_1 \in [16, 70]$
Есть дети	$X_2 \sim \text{Be}(0.25)$
Рабочие/учебные часы	$X_3 \sim \text{Pois}(40)$, $X_3 \in [0, 48]$
Пол (женщина)	$X_4 \sim \text{Be}(0.54)$
Живет один	$X_5 \sim \text{Be}(0.35)$
Доход	$X_6 \sim \text{Lognormal}(10, 0.5^2)$, $X_6 \in [19000, 500000]$
Физическая активность	$X_7 \sim \text{gamma}(\mu = 5, \sigma = 3.54, \text{границы } 0 - 30)$

- **Наличие детей** (X_2) определено биномиальным распределением с параметром $p = 0.25$, где $x = 1$ для людей, у которых есть дети. Таким образом в выборку попали 25% людей с детьми и 75% без детей.
- **Рабочие/учебные часы** (X_3) определены распределением Пуассона с параметром $\lambda = 40$ часов в неделю. Дополнительно мы ограничили диапазон от 0 (отрицательные значения приравниваются к 0) до 48 (максимальное количество часов в неделю согласно МОТ¹) часов в неделю, чтобы исключить экстремально высокие значения. Распределение Пуассона описывает как стандартное значение в 40 часов в неделю, так и возможные вариации, связанные с переработками, неполным графиком и другими причинами.
- **Пол** (X_4) определен биномиальным распределением с параметром $p = 0.54$, где $x = 1$ соответствует женщинам. По данным Росстата в 2024 53.53% населения составили женщины. Таким образом, в выборке 54% женщин и 46% мужчин.
- **Проживание в одиночестве** (X_5) определено биномиальным распределением с параметром $p = 0.35$, где $x = 1$ соответствует людям, которые живут одни. Остальные 65% живут с семьей, партнером или соседями.
- **Доход** (X_6) определен логнормальным распределением с параметрами $\mu = 10$ и $\sigma = 0.5$, что соответствует медианному доходу около 22 000 рублей и среднему доходу около 25 000 рублей. Диапазон ограничен от 19 000 (Федеральный прожиточный минимум) до 500 000 рублей в месяц для исключения выбросов. Логнормальное распределение с ограничениями обеспечивает правостороннюю асимметрию (большинство людей имеет средний доход, меньшинство - высокий)
- **Физическая активность** (X_7) определена гамма распределением с параметрами $shape = 2$ и $scale = 2.5$, что соответствует среднему в 5 часов в неделю и стандартному отклонению в 3.54 часа, и границами от 0 (отрицательные значения приравниваются к 0) до 30 часов в неделю. Такой вид распределения был выбран, так как при большом количестве наблюдений оно стремится к нормальному, но при этом обеспечивает правостороннюю перекошенность (не так много людей занимается спортом больше 5 часов в неделю)

2. Описание генерации инструментальной переменной

Наличие промо-подписки (Z) определено биномиальным распределением с параметром $p = 0.4$, где $x = 1$ соответствует клиентам оператора, которые получили промо-подписку.

3. Описание генерации ненаблюдаемых переменных

¹Международная организация труда

Таблица 2: Ненаблюдаемые переменные

Переменная	Распределение
Хронотип "сова"	$U_1 \sim \text{Be}(0.3)$
Самодисциплина	$U_2 \sim U(0, 7)$

- **Хронотип "сова"** (U_1) представлен биномиальным распределением с параметром $p = 0.3$ (по литературным данным в среднем в мире от 20 до 40% людей с вечерним хронотипом.), где $x = 1$ соответствует "совам".
- **Самодисциплина** (U_2) замоделирована равномерным распределением на промежутке от 0 до 7. Равновероятно в выборку могут попасть люди с полным отсутствием самоконтроля, так и максимально дисциплинированные.

4. Описание генерации переменной воздействия (D)

Переменная воздействия $D_i \in \{0, 1\}$ генерируется по логит модели:

$$D_i = 1[D_i^* > 0]$$

Уравнение переменной воздействия

$$D_i^* = \beta_0 + \beta_z Z_i + \sum_j \gamma_j X_{ji} + \delta_1 U_{1i} + \delta_2 U_{2i} + \varepsilon_i, \quad \varepsilon_i \sim \text{Log}(0, 1)$$

с параметрами:

$$\beta_0 = 1.15, \beta_z = 1.3$$

Таблица 3: Генерация переменной воздействия D (склонность к подписке)

Переменная	Коэффициент	Обоснование направления
X_1 (возраст)	-0.04	С возрастом реже оформляют подписки
X_2 (дети)	+0.35	Семейные подписки, детский контент
X_3 (занятость)	+0.01	Фоновый просмотр после тяжелого дня
X_4 (пол)	+0.15	Предположение
X_5 (живет один)	-0.20	Меньше совместного досуга
X_6 (доход)	$+6 \times 10^{-6}$	Выше доход, значит легче платить
U_1 (хронотип «сова»)	+0.60	Совы активны ночью, чаще пользуются стримингом
U_2 (самоконтроль)	-0.40	Высокий самоконтроль снижает вероятность подписки
Z (промо-подписка)	+1.30	Промо снижает финансовый барьер входа

Шум ε_i имеет стандартное логистическое распределение, что соответствует модели логистической регрессии для бинарного выбора. Пороговое значение равно нулю, то есть человек оформляет подписку, если суммарный коэффициент положителен.

5. Описание генерации зависимой переменной

Сначала был определен базовый сценарий, когда подписки нет

$$\mu_i = \alpha_0 + \sum_j \phi_j X_{ji} + a X_{7i} + b X_{7i}^2 + \xi X_{2i} X_{3i} + \varphi_1 U_{1i} + \varphi_2 U_{2i}$$

Таблица 4: Генерация зависимой переменной Y (часы сна в сутки)

Переменная	Коэффициент	Обоснование
$\alpha_0 = 7.5$ ч — базовый уровень сна		
X_1 (возраст)	-0.02	С возрастом сон сокращается
X_2 (дети)	-0.30	Ночные пробуждения из-за детей
X_3 (занятость)	-0.02	Высокая загрузка сокращает время сна
X_4 (пол)	+0.20	Женщины в выборке спят чуть больше
X_5 (живет один)	+0.15	Никто не будит ночью
X_6 (доход)	$+5 \times 10^{-7}$	Гибкий график
X_7, X_7^2 (физ. активн.)	+0.0308; -0.0006	Умеренная нагрузка увеличивает сон, чрезмерная - снижает
$X_2 \cdot X_3$ (дети $\times$ занятость)	-0.02	Сон работающих родителей проседает сильнее суммы эффектов
U_1 (хронотип «сова»)	-0.30	Совы ложатся позже и меньше спят
U_2 (самоконтроль)	+0.15	Строгий режим сна

с параметром $\alpha_0 = 7.5$ ч

Потенциальные исходы определяются как:

$$Y_i(0) = (\mu_i + \varepsilon_i)$$

$$Y_i(1) = (\mu_i + \tau_i + \varepsilon_i),$$

где $\varepsilon_i \sim \mathcal{N}(0, 0.3^2)$, $Y_i \in [3, 12]$,

а индивидуальный эффект воздействия задается как:

$$\tau_i = -0.3 - 0.2U_{1i} + 0.05X_{2i} + 0.07U_{2i}$$

Базовый эффект подписки составляет 18 минут, то есть столько теряет человек без самоконтроля, детей и без хронотипа "сова". Совы теряют дополнительно до 12 минут. Для реалистичности в эффект воздействия добавлен X_2 (наличие детей) с небольшим положительным коэффициентом, так как родители часто встают рано, стриминг не сильно сдвигает их режим, а контент смотрят днем вместе с детьми. Высокий самоконтроль также смягчает эффект - максимально дисциплинированные люди спят на 30 минут больше, чем люди с отсутствием самоконтроля. Итого, из-за компенсирующих вкладов средний по выборке эффект воздействия (ATE) отнимает 6 минут сна.

Задание 2.2. Симулируйте данные в соответствии с предполагаемым процессом и приведите корреляционную матрицу, а также таблицу со следующими описательными статистиками:

- Для непрерывных переменных: выборочное среднее, выборочное стандартное отклонение, медиана, минимум и максимум.
- Для бинарных: доля и количество единиц.

Указания:

- Необходимо сгенерировать не менее 1000 наблюдений

Таблица 5: Описательные статистики непрерывных переменных

Переменная	Среднее	Ст. откл.	Медиана	Мин.	Макс.
Y (часы сна)	6.380	0.762	6.450	3.627	8.586
X_1 (возраст, лет)	35.592	11.343	35.230	16.000	70.000
X_3 (рабочие часы, ч/нед)	39.641	5.670	40.000	20.000	48.000
X_6 (доход, руб./мес.)	27016.494	11609.141	22086.269	19000.000	116008.323
X_7 (физ. активность, ч/нед)	5.084	3.643	4.229	0.068	30.000

Таблица 6: Описательные статистики бинарных переменных

Переменная	Доля единиц	Количество
D (стриминг-подписка)	0.439	2194
Z (промо оператора)	0.400	1999
X_2 (есть дети)	0.257	1286
X_4 (пол)	0.548	2740
X_5 (живет один)	0.351	1755

- Доля единиц не должна быть меньше 0.1 или больше 0.9 ни для одной из бинарных переменных.

Ответ.




Рис. 1: Корреляционная матрица наблюдаемых переменных

Задание 2.3. Разделите выборку на обучающую и тестовую. Тестовая выборка должна включать от 20% до 30% наблюдений.

Ответ.

Выборка была разделена на тестовую и тренировочную в соотношении 25/75

количество наблюдений в тестовой выборке: 1250
количество наблюдений в обучающей выборке: 3750

Задание 2.4. В случае необходимости проведите дополнительный анализ и приведите дополнительные комментарии о процессе генерации данных, описательных статистиках и т.д.

Ответ.

На данном этапе можно увидеть, что условия хорошего инструмента соблюдены.

Релевантность: $\text{Corr}(Z, D) = 0.25$

Экзогенность: $\text{Corr}(Z, Y) = -0.03$, корреляция с контрольными переменными также неотличима от 0

3 Классификация

Здесь и в последующих разделах ненаблюдаемые переменные, сгенерированные ранее с целью создания эндогенной переменной воздействия, не включаются в качестве признаков ни в одну из моделей. В каждом из заданий, если не сказано иного, необходимо использовать **хотя бы 3** (на ваш выбор) из следующих методов: наивный Байесовский классификатор, метод ближайших соседей, случайный лес, градиентный бустинг и логистическая регрессия.

Задание 3.1. Отберите признаки, которые могут быть полезны при прогнозировании переменной воздействия. Не включайте в число этих признаков целевую переменную.

Ответ.

Были отобраны все контрольные переменные и инструментальная переменная в список признаков для классификации. Все признаки были стандартизированы (среднее = 0, стандартное отклонение = 1). Параметры стандартизации рассчитывались только по обучающей выборке и применялись к тестовой, чтобы избежать утечки информации из теста. Стандартизация важна для метода ближайших соседей, поскольку он чувствителен к масштабу признаков. Случайному лесу и градиентному бустингу масштабирование не требуется, поэтому они обучались на исходных признаках. Также была применена стратификационная кросс-валидация на 5 частей (CV). Это сделано для избежания переобучения на этапе подбора гиперпараметров модели. Доли $D = 1$ в тестовой и обучающей выборке равны 0.438 и 0.439 соответственно, то есть примерно совпадают. Таким образом, базовый уровень точности (доля наиболее частого класса) составляет около 0.561, и именно с этим значением следует сравнивать ассигасу моделей.

Задание 3.2. Для каждого метода:

- Оцените точность (ассигасу), используя произвольные значения гиперпараметров на обучающей и тестовой выборках и с помощью кросс-валидации.
- С помощью кросс-валидации на обучающей выборке подберите оптимальные значения гиперпараметров.
- В одной таблице укажите исходные и подобранные значения гиперпараметров, а также кросс-валидационную точность (ассигасу) и точность на тестовой до и после тюнинга
- Обсудите наличие или отсутствие признаков переобучения модели.

Проинтерпретируйте полученные результаты.

Повышенная сложность: подберите на обучающей выборке оптимальные значения гиперпараметров случайного леса ориентируясь на значения ООВ (out-of-bag) ошибки. Со-

поставьте гиперпараметры и точность на тестовой выборке для случайного леса в зависимости от того, используется кросс-валидация или ООВ ошибка. Объясните преимущества и недостатки ООВ ошибки по сравнению с кросс-валидацией.

Ответ.

Были выбраны следующие три метода: **случайный лес, градиентный бустинг и метод ближайших соседей**

1. Случайный лес

В качестве исходной версии были использованы параметры метода: 50 деревьев и максимальная глубина - 5.

Далее использовался тюнинг со следующими комбинациями:

Таблица 7: Параметры для настройки случайного леса

Параметр	Значения для перебора
количество деревьев	100, 200, 300
максимальная глубина	5, 10, None
минимальное число наблюдений для разбиения	2, 5
сколько признаков рассматривается	'sqrt', 'log2'

Как показано в таблице 8, точность на кросс-валидационной и тестовой выборках немного лучше у модели с подобранными гиперпараметрами. Еще можно заметить, что ассигасу модели с тюнингом на тестовой выборке практически не отличается от этого показателя на CV-выборке. Разрыв между точностью на обучающей выборке (0.6709) и на кросс-валидации (0.6379) невелик, что говорит об отсутствии существенного переобучения: ограничение глубины деревьев и усреднение прогнозов по ансамблю снижают дисперсию модели.

Также был реализован подбор гиперпараметров по ООВ-ошибке через ручной перебор сетки параметров с `oob_score = True`.

По результатам тюнинга обе модели выбрали схожие гиперпараметры с единственным расхождением в параметре `max_features`: CV предпочел `sqrt`, а ООВ - `log2`. Ограничение числа признаков, рассматриваемых при каждом разбиении (`sqrt` или `log2` от общего числа), снижает корреляцию между деревьями и тем самым уменьшает дисперсию ансамбля. ООВ-ассигасу и кросс-валидационная ассигаса практически идентичны, ООВ немного лучше. А точность на тестовой выборке оказалась чуть выше у CV-оценки.

Таблица 8: Сравнительная таблица для случайного леса

Модель	Гиперпараметры				Accuracy		
	n_estimators	max_depth	samples_split	max_features	Train	CV / OOB	Test
Базовый	50	5	2 (default)	'sqrt' (default)	0.6709	0.6379	0.6400
С тюнингом	300	5	2	'sqrt'	0.6696	0.6445	0.6456
ООВ	300	5	2	'log2'	-	0.6480	0.6424

Преимущество ООВ перед кросс-валидацией, во-первых, заключается в том, что не требуется дополнительных разбиений выборки, а значит сокращается время вычислений. А во-вторых, очень важно, что ООВ использует для валидации все обучающие наблюдения (каждое попадает в ООВ примерно 37% деревьев), тогда как при CV

каждое наблюдение используется для валидации лишь в одном фолде из пяти.

Главный *недостаток* ООВ заключается в том, что его можно применить только для ансамблевых методов типа случайного леса. Во-вторых, ООВ-оценка может быть смещенной при малых выборках: если мало деревьев, некоторые наблюдения могут редко попадать в ООВ-множество, что снижает надежность оценки. В нашем случае на обучающей выборке (при $n = 3750$ и 300 деревьях) этот эффект минимален. В-третьих, кросс-валидация позволяет оценивать любую модель и любой критерий качества, тогда как ООВ позволяет оценить только ассигасу (или иную метрику, поддерживаемой параметром `oob_score`).

2. Градиентный бустинг

Таблица 9: Параметры для настройки градиентного бустинга

Параметр	Значения для перебора
количество деревьев	100, 200
максимальная глубина	3, 5
минимальное число наблюдений для разбиения	2, 5
шаг обучения	0.05, 0.1, 0.2

Таблица 10: Сравнительная таблица для градиентного бустинга

Модель	Гиперпараметры				Accuracy		
	n_estimators	max_depth	learning_rate	min_samples_split	Train	CV	Test
Базовый	50	3	0.1	2 (default)	0.6797	0.6379	0.6424
С тюнингом	100	3	0.05	5	0.6797	0.6403	0.6464

Гиперпараметры модели с тюнингом для градиентного бустинга отличаются от базовой версии: число деревьев и количество наблюдений для разбивки увеличены, а шаг, наоборот уменьшен. Глубина одинаковая в обоих случаях. Точность у такой модели стала лучше, чем у базовой и на кросс-валидационной, и на тестовой выборках. Уменьшение шага обучения при увеличении числа деревьев стандартный прием регуляризации для бустинга. Меньший шаг снижает риск переобучения, а большее число деревьев компенсирует замедление обучения.

Перед тем как перейти дальше, необходимо прокомментировать тот факт, что значение *Accuracy* для базовой модели и модели с тюнингом совпали (0.6797). Так происходит, потому что уменьшение шага обучения компенсируется увеличением числа деревьев, получается, что суммарный вклад в обучение модели оказывается очень близким. При этом на кросс-валидационной и тестовой выборках точность модели с тюнингом немного выше: меньший шаг обучения снижает риск переобучения, что и является стандартным для бустинга приемом регуляризации.

3. Метод ближайших соседей (KNN)

Модель с тюнингом подобрала гиперпараметры, отличные от базовых: увеличено число соседей (с 5 до 50), выбраны взвешивание по расстоянию (distance) и метрика Манхэттена. Точность на обучающей выборке у тюнигованной модели равна 1.0000,

Таблица 11: Параметры для настройки KNN

Параметр	Значения для перебора
число соседей	3, 5, 10, 20, 50
веса	"uniform" "distance"
тип	"euclidean" "manhattan"

Таблица 12: Сравнительная таблица для метода ближайших соседей (KNN)

Модель	Гиперпараметры			Accuracy		
	n_neighbors	weights	metric	Train	CV	Test
Базовый	5	'uniform' (default)	'minkowski' (default)	0.7333	0.5907	0.5992
С тюнингом	50	'distance'	'manhattan'	1.0000	0.6485	0.6256

однако это не свидетельствует о переобучении в обычном смысле, так как при взвешивании по расстоянию ($\text{weights} = \text{distance}$) каждое обучающее наблюдение является своим собственным ближайшим соседом с бесконечно большим весом, поэтому на обучающей выборке модель всегда воспроизводит истинные метки. Качество модели следует оценивать по кросс-валидации и тесту, где точность составляет 0.6485 и 0.6256. Признаки переобучения отчетливо видны у базовой модели: при $k = 5$ точность на обучающей выборке (0.7333) существенно превышает кросс-валидационную (0.5907), разрыв около 14 процентных пунктов. Малое число соседей приводит к высокой дисперсии прогнозов. Увеличение числа соседей до 50 при тюнинге сглаживает прогноз и устраняет переобучение: кросс-валидационная точность равна 0.6485.

Задание 3.3. Повторите предыдущий пункт, используя любой альтернативный критерий качества модели. Обоснуйте возможные преимущества и недостатки этого альтернативного критерия.

Повышенная сложность: дополнительно самостоятельно запрограммируйте не представленный в стандартных библиотеках критерий качества и используйте его для тюнинга гиперпараметров. Сравните результат стандартного и вашего критериев, а также опишите его преимущества и недостатки: в каких случаях его разумно применять, а в каких случаях он может оказаться не очень полезен.

Ответ.

В качестве альтернативного критерия выбрана F1-мера по классу подписчиков ($D = 1$). F1-мера, гармоническое среднее precision и recall, напрямую штрафуют и пропуска подписчиков (FN), и ложные срабатывания (FP) по интересующему классу и не засчитывает в заслугу модели правильно распознанные TN.

Тюнинг всех трех моделей повторен с критерием F1 на тех же сетках гиперпараметров и той же стратифицированной 5-блочной кросс-валидации. Дополнительно рассмотрен критерий F_β с $\beta = 2$, который придает recall вчетверо больший вес, чем precision ($\beta^2 = 4$). Далее для краткости обозначаем эту метрику F_2 .

Таблица 13: Сравнение критериев качества при тюнинге (раздел 3.3)

Модель	Асс (Асс-тюнинг)	F1 (F1-тюнинг)	Асс (F1-тюнинг)	F_2 (F_2 -тюнинг)	Асс (F_2 -тюнинг)
RF	0.6456	0.5565	0.6392	0.5168	0.6144
GB	0.6464	0.5553	0.6464	0.5350	0.6168
KNN	0.6256	0.5430	0.6256	0.5171	0.6096

Отбор по F1 смещает выбор гиперпараметров в сторону конфигураций с более высоким recall: случайный лес при тюнинге по ассигасу предпочитал неглубокие деревья (`max_depth=5`, `max_features=sqrt`), а при тюнинге по F1 выбрал более гибкую конфигурацию (`max_depth=10`, `max_features=log2`, `n_estimators=100`). При этом ассигасу после тюнинга по F1 почти не меняется (RF 0.6456 $\rightarrow$ 0.6392, GB и KNN без изменений), то есть при дисбалансе классов F1 и ассигасу ранжируют конфигурации по-разному, не вступая в сильный конфликт по общей точности.

Переход к F_2 усиливает этот эффект: критерий толкает модели предсказывать класс 1 чаще, что снижает ассигасу по всем трем моделям (RF 0.6392 $\rightarrow$ 0.6144, GB 0.6464 $\rightarrow$ 0.6168, KNN 0.6256 $\rightarrow$ 0.6096). Случайный лес при тюнинге по F_2 выбрал максимально гибкую конфигурацию (`max_depth=None`, `n_estimators=200`), что согласуется с ориентацией на recall за счет роста числа ложных срабатываний.

Преимущества F1 и F_β перед ассигасу: устойчивость к дисбалансу классов; фокус на содержательно важном классе подписчиков, который и является целью адресной программы из задания 3.7; сведение precision и recall в один скаляр, причем F_β позволяет явно задать относительную цену FN и FP через параметр β . Недостатки: обе метрики полностью игнорируют истинно отрицательные прогнозы (специфичность), поэтому в постановке, где важно не беспокоить неподписчиков, могут вводить в заблуждение; они рассчитываются при фиксированном пороге 0.5 и не учитывают ранжирующую способность модели, в отличие от AUC из задания 3.4; выбор β остается субъективным и не привязан к конкретным денежным величинам.

Задание 3.4. Постройте ROC-кривые для ваших моделей (с подобранными гиперпараметрами) и сравните их по AUC на тестовой выборке. Обсудите преимущества и недостатки AUC по сравнению с ACC в контексте вашей содержательной задачи.

Ответ.




Рис. 2: ROC-кривые классификаторов (тестовая выборка)

ROC-кривые для трех моделей с подобранными гиперпараметрами представлены на

рисунке 2. По площади под кривой (AUC) на тестовой выборке модели упорядочиваются следующим образом:

1. Случайный лес (AUC = 0.6748)
2. Градиентный бустинг (AUC = 0.6732)
3. Метод ближайших соседей (AUC = 0.6525).

Все три кривые проходят выше, чем случайный классификатор, то есть модели предсказывают лучше, чем случайный выбор. Однако уровень предсказательной способности ограничен и это объясняется тем, что в числе признаков отсутствуют ненаблюдаемые факторы (хронотип и самоконтроль). Кривая метода ближайших соседей расположена ниже остальных и имеет более ступенчатый вид, поскольку взвешенные по расстоянию вероятности принимают ограниченное число различных значений.

Метрика AUC оценивает способность модели правильно ранжировать TPR и FPR, в то время как АСС (ассигасу) оценивает результат одной конкретной границы. Если неоптимально выбирать эту границу, то АСС может исказить результаты. Кроме того, AUC устойчив к несбалансированности классов. Например, в нашей выборке доля $D = 1$ составляет лишь 0.439, поэтому АСС при пороге 0.5 может оказаться неточным. AUC лишен этого недостатка, так как учитывает соотношение долей верно и ложно классифицированных при всех возможных порогах.

Недостаток AUC заключается в том, что он не способен оценивать качество конкретных решений при фиксированном пороге, в отличие от АСС. AUC также не учитывает различную стоимость ошибок разных типов, что существенно для прикладной задачи: пропуск потенциального подписчика и ошибочное отнесение к подписчикам имеют разную цену.

Задание 3.5. Для любой модели (на ваш выбор) постройте матрицу ошибок на тестовой выборке при стандартном пороге классификации 0.5. Обсудите, какие ошибки встречаются чаще и с чем это может быть связано.

Ответ.

TP = 253 - есть подписка, правильно определил

TN = 554 - нет подписки, правильно определил

FP = 148 - нет подписки, определил как "есть подписка"

FN = 295 - есть подписка, определил как "нет подписки"

Матрица ошибок построена для модели случайного леса (лучшей по AUC) на тестовой выборке при пороге классификации 0.5 и представлена на рисунке 3. Точность модели (ассигасу) составляет 0.6456, точность по классу подписчиков (precision) равна 0.631, полнота (recall) равна 0.462. Ложно отрицательные прогнозы встречаются заметно чаще ложно положительных (295 против 148). Это значит, что модель чаще ошибочно принимает тех, у кого есть подписка, за тех, у кого ее нет, чем наоборот. Данные ошибки могут быть связаны с тем, что в выборке преобладает класс без подписки (доля $D = 0$ равна 0.562), и при стандартном пороге 0.5 модель смещена в сторону прогнозирования более частого класса. В результате полнота (recall) по классу подписчиков оказывается невысокой (0.462), то есть модель распознает менее половины тех, кто действительно приобрел подписку.

Задание 3.6. Для модели из предыдущего пункта рассмотрите не менее двух порогов, отличных от 0.5, и рассчитайте для каждого из них АСС, Precision и Recall. Результаты представьте в виде таблицы. Обсудите, как изменение порога влияет на распределение ошибок прогнозов различного типа. Уточните, какие из ошибок могут быть более существенными исходя из контекста вашей экономической задачи. Содержательно обоснуйте, какой из двух рассмотренных порогов может быть предпочтительнее.




Рис. 3: Матрица ошибок: random forest (порог 0.5)

Таблица 14: Метрики при различных порогах классификации

Порог	Accuracy	Precision	Recall	F1	FP	FN
0.3	0.5056	0.4679	0.9325	0.6232	581	37
0.5	0.6456	0.6309	0.4617	0.5332	148	295
0.7	0.5616	0.0000	0.0000	0.0000	0	548

Ответ.

При снижении порога увеличивается полнота *recall*: при пороге 0.7 $recall = 0$, при пороге 0.3 $recall = 0.9325$. Так же при снижении порога уменьшается количество ложно определенных подписчиков (с 548 при пороге 0.7 до 37 при пороге 0.3). Это значит, что модель распознает почти всех подписчиков. Однако со снижением порога растет число ложно определенных подписчиков (*FP* от 0 до 581) и также снижается точность (0.5056, самое низкое значение среди трех вариантов порога).

При пороге 0.5 наблюдается обратная картина: высокая точность ($precision = 0.631$) при средней полноте ($recall = 0.462$). Таким образом получается, что понижение порога переносит ошибки из категории ложно отрицательных в категорию ложно положительных, и наоборот.

Порог 0.7 оказывается самым интересным - при таком пороге ни одно наблюдение не получает прогнозируемую вероятность подписки выше 0.7, поэтому всем объектам присваивается класс "нет подписки". Точность при этом (0.5616) - это просто доля в выборке тех, у кого нет подписки, а *precision* и *recall* по классу подписчиков вообще обращаются в ноль. Это объясняется ограниченной предсказательной способностью модели: ключевые факторы подписки (хронотип и самоконтроль) ненаблюдаемы, поэтому оценки вероятности концентрируются вблизи базовой доли и редко превышают 0.5.

Необходимый порог для модели обычно определяется исходя из контекста поставлен-

ной задачи. Если цель состоит в том, чтобы охватить как можно больше потенциальных подписчиков (например, для таргетированного предложения), то пропустить реального подписчика хуже, чем случайно отправить предложение человеку без подписки. Для такой ситуации предпочтителен низкий порог 0.3, который максимизирует полноту. Если же необходимо экономить на нецелевых действиях, то ситуация становится обратной и уже более важно не тратить ресурсы на тех, у кого подписки нет. При такой задаче предпочтительнее установить порог в 0.5.

Задание 3.7. Обсудите прикладную задачу, для решения которой может использоваться ваша классификационная модель. Опишите конкретного экономического агента(заказчика), который может быть заинтересован в использовании ваших прогнозов. Укажите, какие действия целесообразно предпринимать заказчику в зависимости от того, является ваш прогноз положительным или отрицательным. Исходя из этих действий и содержательных соображений предположите цены различных видов прогнозов. Руководствуясь критерием максимизации прибыли на обучающей выборке подберите оптимальный порог прогнозирования для каждого из методов и сравните прибыли на тестовой выборке при соответствующих порогах. Результат представьте в форме таблицы, в которой должны быть указаны прибыли на тестовой выборке. Проинтерпретируйте полученный результат, в частности, объяснив, как подобранное на данных оптимальное значение порога соотносится с экономической интуицией.

Повышенная сложность: предложите, содержательно обоснуйте и примените собственную, отличную от линейной функцию прибыли от прогнозов.

Ответ.

В качестве заказчика рассматривается государство, реализующее программу охраны здоровья сна населения. Классификационная модель используется для выявления граждан, имеющих стриминговую подписку, с целью адресного направления им профилактических материалов о гигиене сна – информационных рассылок, приглашений на просмотры и рекомендаций по режиму дня. Действия заказчика в зависимости от прогноза определяются следующим образом. При положительном прогнозе $\hat{D} = 1$ гражданину направляются профилактические материалы. При отрицательном прогнозе $\hat{D} = 0$ никаких действий не предпринимается, что позволяет экономить бюджет программы. Исходя из этой логики, определяется следующая матрица выплат.

Таблица 15: Матрица ошибок с цветовой индикацией

	Предсказанные значения	
	Positive	Negative
Positive	TP: +30	FN: -20
Negative	FP: -10	TN: 0

Заметим, что штраф за FN вдвое превышает штраф за FP: государству важнее не пропустить человека из группы риска, чем сэкономить на лишней рассылке. Оптимальный порог классификации подбирается путем максимизации суммарной прибыли на обучающей выборке при переборе 100 равномерно распределенных значений от 0.05 до 0.95. Результаты представлены в таблице 16.

Все три модели демонстрируют оптимальный порог ниже стандартного значения 0.5, что соответствует экономической интуиции: поскольку штраф за FN превышает штраф за FP, модели выгодно чаще предсказывать класс 1, снижая число пропущенных подписчиков за счет роста числа ложных срабатываний. Суммарная прибыль при оптимальном пороге превышает прибыль при стандартном пороге 0.5 для всех моделей, что подтверждает целесообразность содержательно мотивированного выбора порога.

Таблица 16: Прибыль на тестовой выборке

Модель	Опт. порог (train)	Прибыль (test, opt)	Прибыль (test, 0.5)
Random Forest	0.277	8850	210
Gradient Boosting	0.223	9100	1140
KNN	0.050	9420	960




Рис. 4: Зависимость прибыли от порога классификации

Стоит упомянуть интересное для интерпретации значение порога в 0.05 для KNN. Это соответствует решению, при котором всем наблюдениям присваивается класс 1: прибыль 9420 совпадает с прибылью тривиального классификатора ($548 \cdot 30 - 702 \cdot 10 = 9420$). Поэтому наибольшая прибыль KNN достигается не за счет качества модели, а за счет того, что штраф за FN вдвое выше штрафа за FP.

В качестве нелинейной функции прибыли предлагается модификация штрафа за ложноположительные прогнозы с учетом эффекта «усталости от рассылок»: при высокой доле FP среди всех отрицательных наблюдений граждане начинают игнорировать профилактические материалы, что снижает их эффективность. Штраф за каждый FP задается как $-10 \cdot (1 + FP_rate)$, где FP_rate - доля ложных срабатываний среди всех истинно отрицательных наблюдений. Таким образом, чем агрессивнее модель предсказывает класс 1, тем выше совокупный штраф за каждое ложное срабатывание. Это приводит к смещению оптимального порога вправо по сравнению с линейной функцией прибыли, что отражено в таблице 17.

Таблица 17: Сравнение линейной и нелинейной функций прибыли

Модель	Опт. порог (нелин.)	Прибыль (нелин., test)	Прибыль (лин., test)
Random Forest	0.368	4514.430	8850
Gradient Boosting	0.350	4166.866	9100
KNN	0.050	2400.000	9420

Перспективным расширением данного исследования могло бы стать встраивание классификационной модели в макроэкономический анализ. В частности, государство могло бы быть заинтересовано в оценке совокупного ущерба для ВВП, связанного со снижением продуктивности работников вследствие недосыпания, обусловленного потреблением стримингового контента. Однако такой анализ требует дополнительных данных, например, индивидуальных показателей производительности труда и их связи с продолжительностью сна, которые выходят за рамки настоящего исследования.

Задание 3.8. Опишите предполагаемые связи между переменными в форме ориентированного ациклического графа (DAG). Обучите структуру байесовской сети на обучающей выборке и сравните точность прогнозов вашего и обученного DAG на тестовой выборке.

Повышенная сложность: постройте ROC-кривую для байесовской сети и сравните ее AUC с другими методами.

Ответ.

Все контрольные переменные ($X_1 - X_7$) и инструментальная переменная Z рассматриваются как родительские узлы переменной воздействия D . Направления связей обоснованы в разделе 2: промо-подписка оператора снижает барьер входа ($Z \rightarrow D$), возраст отрицательно связан с вероятностью подписки ($X_1 \rightarrow D$), наличие детей повышает ее через семейный контент ($X_2 \rightarrow D$), занятость способствует фоновому просмотру ($X_3 \rightarrow D$), доход определяет финансовую доступность подписки ($X_6 \rightarrow D$).

Поскольку Байесовские сети в используемой библиотеке `pgmpy` работают исключительно с дискретными переменными, непрерывные переменные X_1, X_3, X_6, X_7 дискретизируются на три равных по ширине интервала. Условные вероятности оцениваются с помощью байесовского оценщика с априорным распределением `BDeu` и размером эквивалентной выборки 10, что обеспечивает сглаживание при малом числе наблюдений в отдельных ячейках. Для обучения альтернативной структуры применяется алгоритм `Hill Climb Search` с критерием `BIC`. Алгоритм перебирает возможные добавления, удаления и развороты ребер, на каждом шаге выбирая то изменение, которое максимально улучшает `BIC-score`, штрафующий за сложность структуры.

Для каждого объекта из тестовой выборки модель вычисляет вероятность того, что воздействие сработает ($D = 1$), с учетом всех известных признаков этого объекта. Расчет выполняется методом исключения переменных (`Variable Elimination`). В случаях, когда комбинация значений не встречалась в обучающей выборке, в качестве вероятности используется значение 0.5. Результаты сравнения всех классификаторов представлены в таблице 18.

Таблица 18: Сравнение точности всех классификаторов

Модель	Accuracy (test)	AUC (test)
Random Forest	0.6456	0.6748
Gradient Boosting	0.6464	0.6732
KNN	0.6256	0.6525
Байесовская сеть (заданный DAG)	0.6008	0.6071
Байесовская сеть (обученный DAG)	0.6320	0.6670

В целом, Байесовские сети уступают ML-моделям как по ассигасу, так и по AUC, что объясняется рядом ограничений. Во-первых, дискретизация непрерывных переменных неизбежно приводит к потере информации. Во-вторых, Байесовская сеть предполагает условную независимость переменных при заданных родителях, тогда как в данных могут присутствовать более сложные взаимодействия. В-третьих Байесовские сети требуют больших вычислительных затрат, и соответственно хуже работают на больших выборках, в отличие от градиентного бустинга или случайного леса. Исключение составляет обученный DAG, AUC которого незначительно превысил AUC метода ближайших соседей. Данный результат, по всей видимости, объясняется особенностями дискретизации: разбиение признаков случайно оказалась удачной для данного разбиения на обучающую и тестовую выборки. Кроме того, при $n=5000$ и 8 признаках KNN с оптимальным числом соседей 50 фактически усредняет предсказания по большому числу наблюдений, что снижает его чувствительность к локальным закономерностям.

Тем не менее, Байесовская сеть обладает рядом преимуществ: она явно кодирует причинно-следственную структуру, интерпретируема и позволяет проводить вероятностный вывод

в условиях частично наблюдаемых данных. ROC-кривые всех моделей представлены на Рисунке 5.




Рис. 5: ROC-кривые для всех моделей

Наибольший AUC демонстрирует Random Forest (0.6748), наименьший - Байесовский классификатор с заданными условиями (0.6071).

Задание 3.9. На основании проведенного анализа выберите **лучший** и **худший** из обученных классификаторов. Обсудите полученный результат.

Повышенная сложность: необходимо самостоятельно сформулировать разумный критерий, в соответствии с которым будет определяться лучшая и худшая модели.

Ответ.

Для определения лучшей и худшей модели применяются два критерия. Первый - составной статистический критерий, представляющий собой взвешенную сумму AUC (вес 0.6) и ассигасу (вес 0.4) на тестовой выборке. AUC получает больший вес, поскольку является более информативной метрикой: в отличие от ассигасы, он не зависит от выбора порога классификации и оценивает способность модели ранжировать наблюдения по вероятности принадлежности к классу 1 при всех возможных порогах. Второй - практический критерий, представляющий собой суммарную прибыль государственной профилактической программы на тестовой выборке при оптимальном пороге, подобранном на обучающей выборке в соответствии с матрицей выплат из пункта 3.7.

По составному статистическому критерию лучшей моделью является Random Forest со значениями ассигасы = 0.6456 и AUC = 0.6748, что дает составной балл 0.6631. Случайный лес превзошел остальные модели по AUC, что свидетельствует о его наилучшей способности различать подписчиков. Это объясняется устойчивостью ансамблевого метода к шуму и переобучению. По тому же критерию худшей моделью является Байесовская сеть с заданным DAG (Ассигаса=0.6008, AUC=0.6071, составной балл 0.6046), что объясняется потерей информации при дискретизации и ограничениями предположения об условной независимости признаков.

По практическому критерию ситуация меняется: лучшей моделью становится KNN с прибылью 9420 руб., тогда как Random Forest занимает лишь третье место с прибылью

8850 руб., несмотря на наилучший AUC. Объяснение кроется в оптимальном пороге: KNN выбирает порог 0.050, то есть фактически классифицирует почти всех наблюдений как подписчиков. Худшей моделью по практическому критерию остается Байесовская сеть с заданным DAG с прибылью 8420 руб.: несмотря на столь же порог 0.050, низкое качество вероятностных предсказаний ($AUC=0.6071$) транслируется в меньшее число верно выявленных подписчиков и наименьшую суммарную прибыль среди всех классификаторов.

Полученные результаты демонстрируют важное наблюдение: модель с наилучшим AUC не обязательно является оптимальной с точки зрения конкретной экономической задачи. В контексте данного исследования статистический критерий представляется более релевантным, поскольку столь низкий оптимальный порог KNN (0.050) фактически означает отказ от избирательности модели: при пороге, близком к нулю, модель почти всегда предсказывает класс 1 вне зависимости от признаков наблюдения.

Задание 3.10. Повышенная сложность: включите в анализ дополнительный метод классификации, не рассматривавшийся в курсе и не представленный в `skikit-learn`. Опишите данный метод (принцип работы, преимущества и недостатки) и осуществите тюнинг гиперпараметров. Сопоставьте его точность на тестовой выборке с точностью лучшего из обученных вами ранее методов. Добавление обычной регуляризации к классическим методам не считается отдельным методом.

Ответ.

XGBoost - реализация градиентного бустинга над деревьями, не входящая в `skikit-learn`. От рассмотренного ранее градиентного бустинга его отличает ряд особенностей. Во-первых, при построении каждого дерева используется не только градиент, но и вторая производная (гессиян) функции потерь, что дает более точную аппроксимацию оптимального разбиения. Во-вторых, в функцию потерь добавлены штрафы за сложность дерева (число листьев и L_1/L_2 -нормы их весов), что обеспечивает встроенную регуляризацию. В-третьих, поддерживается случайное прореживание наблюдений и признаков, которое снижает корреляцию между деревьями подобно случайному лесу.

Преимущества метода: высокая предсказательная точность на табличных данных, встроенная регуляризация, снижающая риск переобучения, и эффективная параллельная реализация. Недостатки: большое число гиперпараметров, требующих настройки, склонность к переобучению при агрессивных значениях шага и глубины без регуляризации, а также меньшая интерпретируемость по сравнению с одиночным деревом или логистической регрессией.

Базовая версия (100 деревьев, глубина 3, шаг 0.1) дала точность на тесте 0.6392. После тюнинга по сетке (число деревьев, глубина, шаг обучения, доли прореживания наблюдений и признаков) оптимальной оказалась конфигурация со 100 деревьями, глубиной 3, шагом обучения 0.05, долей наблюдений 0.8 и долей признаков 0.8; точность на тесте составила 0.6448, AUC – 0.6763. По сравнению с лучшим из ранее обученных методов (случайный лес, ассурасу 0.6456, AUC 0.6748) XGBoost показал практически идентичную точность и незначительно более высокий AUC.

Таблица 19: Сравнительная таблица для XGBoost

Модель	Гиперпараметры					Accuracy	
	деревья	глубина	шаг	доля набл.	доля призна.	CV	Test
Базовый	100	3	0.10	1.0	1.0	0.6331	0.6392
С тюнингом	100	3	0.05	0.8	0.8	0.6405	0.6448

Задание 3.11. В случае необходимости проведите дополнительный анализ.

Ответ.

4 Регрессия

В каждом задании, если не сказано иного, необходимо использовать **хотя бы 3** (на ваш выбор) из следующих методов: случайный лес, метод наименьших квадратов, метод ближайших соседей, градиентный бустинг. Переменную воздействия в число признаков не включайте.

Задание 4.1. Отберите признаки, которые могут быть полезны при прогнозировании целевой (зависимой) переменной. Не включайте в их число переменную воздействия.

Ответ.

Для прогнозирования целевой переменной были выбраны все наблюдаемые признаки, так как они оказывают влияние на целевую переменную (среднее количество сна). Поскольку переменная воздействия (наличие подписки на стриминг) по условию задания не используется, включать в модели инструмент не имеет смысла.

Задание 4.2. Для каждого метода:

- Оцените RMSE и MAPE, используя произвольные значения гиперпараметров на обучающей и тестовой выборках и с помощью кросс-валидации.
- С помощью кросс-валидации на обучающей выборке подберите оптимальные значения гиперпараметров.
- В одной таблице укажите исходные и подобранные значения гиперпараметров, а также RMSE и MAPE, рассчитанные на тестовой выборке и с помощью кросс-валидации (до и после тюнинга).
- Обсудите наличие или отсутствие признаков переобучения модели.

Повышенная сложность: подберите на обучающей выборке оптимальные значения гиперпараметров градиентного бустинга, ориентируясь на значение ООВ ошибки. Сопоставьте гиперпараметры и точность на тестовой выборке для градиентного бустинга в зависимости от того, используется кросс-валидация или ООВ ошибка.

Ответ.

Для построения регрессий были выбраны три метода: метод наименьших квадратов (МНК), случайный лес и градиентный бустинг. Все метрики приведены в часах сна (RMSE) и в процентах (MAPE). Сводные результаты до и после тюнинга представлены в таблице 20.

Таблица 20: Сводная таблица RMSE и MAPE до и после тюнинга (раздел 4)

Модель	Вариант	Train RMSE	CV RMSE	Test RMSE	CV MAPE	Test MAPE
МНК (OLS)	—	0.5252	0.5264	0.5375	6.86%	6.99%
Случайный лес	Базовый	0.5115	0.5374	0.5425	7.00%	7.13%
Случайный лес	Тюнинг	0.4073	0.5335	0.5374	6.95%	7.06%
Град. бустинг	Базовый	0.5052	0.5296	0.5376	6.91%	7.03%
Град. бустинг	Тюнинг	0.5056	0.5303	0.5364	6.92%	7.01%

1. Метод наименьших квадратов (МНК).

У линейной регрессии нет гиперпараметров для настройки, поэтому базовая и финальная версии совпадают. На всех трех выборках ошибка практически одинакова (Train = 0.5252, CV = 0.5264, Test = 0.5375), а MAPE держится на уровне 7%. Учитывая близость train- и cv-ошибки, можно утверждать, что переобучения не произошло и модель не подстраивается под обучающую выборку. МНК объясняет около 53% дисперсии Y .

2. Случайный лес.

В качестве исходной версии взяты 50 деревьев и максимальная глубина 5. Сетка тюнинга приведена в таблице 21.

Таблица 21: Параметры для настройки случайного леса (регрессия)

Параметр	Значения для перебора
количество деревьев	100, 200, 300
максимальная глубина	5, 10, None
минимальное число наблюдений для разбиения	2, 5
сколько признаков рассматривается	'sqrt', 'log2', None

Таблица 22: Сравнительная таблица для случайного леса (регрессия)

Модель	Гиперпараметры				RMSE		
	n_estimators	max_depth	samples_split	max_features	Train	CV	Test
Базовый	50	5	2	1.0	0.5115	0.5374	0.5425
С тюнингом	300	10	5	'sqrt'	0.4073	0.5335	0.5374

После тюнинга обучающая ошибка резко падает (с 0.5115 до 0.4073), а cv- и тестовая ошибки снижаются незначительно (CV с 0.5374 до 0.5335, Test с 0.5425 до 0.5374). Увеличение числа деревьев до 300 и максимальной глубины до 10 повышает гибкость модели, что и объясняет резкое падение ошибки именно на обучающей выборке.

Само по себе превышение кросс-валидационной ошибки не является прямым признаком переобучения. Для случайного леса обучающая ошибка систематически оптимистична, поскольку деревья тесно подгоняются под обучающие наблюдения. Разрыв между Train и CV является ожидаемым и отражает глубину деревьев, а не утрату обобщающей способности. Наблюдаемое расхождение носит умеренный характер. Незначительность выигрыша в CV и Test при существенном падении обучающей ошибки указывает на то, что дополнительная гибкость расходуется преимущественно на подгонку особенностей обучающей выборки и слабо переносится на новые данные: модель близка к пределу точности, достижимому при имеющемся наборе признаков. Близость кросс-валидационной и тестовой ошибок (0.5335 против 0.5374) подтверждает, что кросс-валидация дает надежную оценку качества модели вне обучающей выборки, а усреднение по ансамблю деревьев сдерживает дисперсию прогноза и удерживает переобучение на умеренном уровне.

3. Градиентный бустинг.

Базовая версия: 50 деревьев, глубина 3, шаг обучения 0.1. Сетка тюнинга приведена в таблице 23.

Таблица 23: Параметры для настройки градиентного бустинга (регрессия)

Параметр	Значения для перебора
количество деревьев	100, 200
максимальная глубина	3, 5
шаг обучения	0.05, 0.1, 0.2
минимальное число наблюдений для разбиения	2, 5

Таблица 24: Сравнительная таблица для градиентного бустинга (RMSE и MAPE)

Модель	Гиперпараметры				RMSE			MAPE, %		
	n_est	depth	lr	split	Train	CV	Test	Train	CV	Test
Базовый	50	3	0.1	2	0.5052	0.5296	0.5376	6.57	6.91	7.03
С тюнингом	100	3	0.05	5	0.5056	0.5303	0.5364	6.58	6.92	7.01

Базовая конфигурация и конфигурация, отобранная кросс-валидацией, практически эквивалентны по всем трем оценкам ошибки: обучающая ошибка остается на уровне 0.505 (0.5052 против 0.5056), кросс-валидационная даже незначительно возрастает (0.5296 против 0.5303), а тестовая снижается лишь на тысячные доли (0.5376 против 0.5364). Все наблюдаемые различия лежат в пределах межблочного шума кросс-валидации, поэтому корректно заключить, что тюнинг не дал различимого выигрыша: подбор по сетке не обнаружил конфигурации, превосходящей базовую. Это согласуется с известной устойчивостью градиентного бустинга к умеренным изменениям гиперпараметров при наличии регуляризации шагом обучения. Следует также отметить, что базовая модель (50 деревьев) не входит в перебираемую сетку, поэтому сопоставление базовой и настроенной версий представляет собой сравнение двух различных конфигураций, а не одной модели до и после оптимизации.

Признаков переобучения в настроенной модели не обнаруживается. Малый разрыв между обучающей и кросс-валидационной ошибками (около 0.025) сам по себе не является решающим аргументом, однако его дополняют два более надежных признака: усложнение модели в ходе тюнинга не ухудшило кросс-валидационную и тестовую ошибки, а кросс-валидационная оценка (0.5303) практически совпадает с тестовой (0.5364), что подтверждает надежность кросс-валидации как оценки обобщающей способности. Тестовая ошибка по метрике MAPE составляет около 7.01%, то есть в среднем прогноз отклоняется от фактического значения примерно на 7%. По тестовой ошибке градиентный бустинг (RMSE 0.5364) и случайный лес (RMSE 0.5374) различаются на величину порядка тысячной доли и практически неразличимы.

Подбор по ООВ-ошибке. У градиентного бустинга в используемой реализации нет готовой ООВ-оценки точности, однако при обучении на случайных подвыборках (доля менее 1) доступна оценка пошагового снижения функции потерь на out-of-bag наблюдениях, измеряемых на каждой итерации. Накопленная сумма этих снижений достигает максимума при оптимальном числе деревьев, что и используется для его выбора (по сути ранняя остановка). В отличие от кросс-валидационного подхода, число деревьев здесь не перебирается по сетке, а считывается с ООВ-кривой при заданном верхнем пределе в 300 деревьев; по сетке варьируются лишь шаг обучения, глубина и минимальное число наблюдений для разбиения. Следует учитывать, что кросс-валидационная конфигурация обучалась на полной выборке, тогда как ООВ-подход по построению требует обучения на

случайных подвыборках (80% наблюдений).

Таблица 25: Сопоставление гиперпараметров градиентного бустинга по CV и по OOB

Критерий отбора	Гиперпараметры	Test RMSE	Test MAPE
Кросс-валидация	n_est=100, depth=3, lr=0.05, split=5	0.5364	7.01%
OOB	n_est=295, depth=5, lr=0.2, split=2	0.5803	7.56%

OOB-критерий отобрал заметно более агрессивную конфигурацию: глубокие деревья (глубина 5), высокий шаг обучения (0.2) и почти предельное число деревьев (295 из 300). Эта конфигурация показала на тестовой выборке худшее качество: RMSE 0.5803 против 0.5364 и MAPE 7.56% против 7.01% у кросс-валидации. Причина в ограниченной пригодности использованного OOB-критерия для отбора между конфигурациями.

Во-первых, сравнение конфигураций по величине накопленного снижения OOB-потерь систематически предпочитает те, что наиболее агрессивно уменьшают функцию потерь: больший шаг и большая глубина дают более крупные пошаговые снижения, поэтому критерий смещен в сторону высокого шага и глубоких деревьев. Во-вторых, OOB-оценка вычисляется по одному случайному подвыборочному срезу (доля 0.2) на каждой итерации и зашумлена. Выбор конфигурации как максимума зашумленного критерия порождает селекционное смещение. Побеждает конфигурация, оказавшаяся удачной на конкретной реализации, что не воспроизводится на тестовой выборке. В-третьих, оптимальное число деревьев (295) практически уперлось в верхнюю границу диапазона, то есть критерий не выявил внутреннего оптимума и склонен требовать все большего числа итераций.

Таким образом, OOB-улучшение может быть адекватным инструментом для выбора числа деревьев внутри фиксированной конфигурации, но ненадежно как критерий сравнения различных конфигураций. Это отличает бустинг от случайного леса, где OOB-оценка представляет собой полноценную альтернативу кросс-валидации: в лесу деревья независимы и каждое располагает значительным набором out-of-bag наблюдений, а в бустинге деревья строятся последовательно, OOB-срез на каждой итерации мал и зависит от предыдущих, что и обуславливает его зашумленность. Кросс-валидация оценивает каждую полную конфигурацию на нескольких ротируемых отложенных блоках вследствие чего корректно решает задачу межконфигурационного отбора. В данном случае она обеспечила лучшую обобщающую способность, что делает ее предпочтительной для настройки градиентного бустинга.

Задание 4.3. На основании сделанного анализа выберите лучшую и худшую модели. Обоснуйте сделанный выбор.

Ответ.

Сравнение проводится по ошибке на тестовой выборке (финальные версии), см. таблицу 26.

Таблица 26: Финальное сравнение моделей по тестовой выборке

Модель	Test RMSE	Test MAPE
Градиентный бустинг	0.5364	7.01%
Случайный лес	0.5374	7.06%
МНК (OLS)	0.5375	6.99%

Наилучшие результаты продемонстрировал градиентный бустинг (Test RMSE = 0.5364): он последовательно соединяет слабые деревья, корректируя остатки, и за счет этого улавливает квадратичный вклад X_7 и взаимодействие $X_2 \cdot X_3$, заложенные в DGP.

Хуже всего с прогнозированием количества сна справился МНК ($\text{Test RMSE} = 0.5375$), поскольку линейная спецификация не отлавливает нелинейности, заложенные в истинный процесс.

Следует подчеркнуть, что разрыв между моделями минимальный (около 0.001 часа, примерно 4 секунды), а по MAPE МНК даже формально лучший (6.99%). Можно сказать, что три метода практически эквивалентны для исследуемого DGP. Нелинейность в уравнении Y слишком мала по сравнению с неустраняемым шумом, поэтому гибкие модели почти не имеют преимущества.

Задание 4.4. Повышенная сложность. Включите в анализ дополнительный метод регрессии, не рассматривавшийся в курсе и не представленный в `scikit-learn`. Опишите данный метод (принцип работы, преимущества и недостатки) и осуществите тюнинг гиперпараметров. Сопоставьте точность на тестовой выборке с точностью лучшего из ранее обученных вами методов.

Ответ.

В качестве дополнительного метода выбран CatBoost. Его ключевая особенность заключается в симметричных деревьях: на каждом уровне дерева используется один и тот же признак и порог разбиения, что делает деревья сбалансированными, ускоряет предсказание и работает как дополнительная регуляризация. Кроме того, CatBoost применяет упорядоченный бустинг, что снижает смещение.

Базовая версия: `iterations=300`, `depth=4`, `learning_rate=0.1`. Сетка тюнинга: `iterations` $\in \{300, 500\}$, `depth` $\in \{4, 6\}$, `learning_rate` $\in \{0.03, 0.05, 0.1\}$, `l2_leaf_reg` $\in \{1, 3, 5\}$.

Таблица 27: Сравнительная таблица для CatBoost

Модель	Гиперпараметры				RMSE		
	iterations	depth	learning_rate	l2_leaf_reg	Train	CV	Test
Базовый	300	4	0.1	3 (default)	0.4793	0.5345	0.5372
С тюнингом	300	4	0.03	1	0.5064	0.5251	0.5343

После тюнинга CatBoost снижает шаг обучения до 0.03, благодаря чему обучающая ошибка перестает убегать вниз (Train растет с 0.4793 до 0.5064, то есть переобучение базовой версии устранено), а cv- и тестовая ошибки улучшаются (CV $0.5345 \rightarrow 0.5251$, Test $0.5372 \rightarrow 0.5343$). CatBoost с тюнингом дает лучшую тестовую ошибку среди всех рассмотренных моделей (0.5343 против 0.5364 у градиентного бустинга из `scikit-learn`), хотя выигрыш снова исчисляется тысячными долями часа. Это подтверждает вывод задания 4.3: при заданном DGP качество прогноза ограничено сверху не выбором алгоритма, а долей неустраняемой дисперсии.

5 Эффекты воздействия

При выполнении данного задания необходимо объединить обучающую и тестовую выборки в одну.

Задание 5.1. Математически запишите выражения для ATE и LATE (с учетом специфики обозначений ваших переменных). Содержательно проинтерпретируйте, что они отражают в вашем исследовании.

Ответ.

В наших обозначениях бинарная переменная воздействия D_i – наличие подписки, Z_i – промо-подписка оператора (инструмент), Y_i – продолжительность сна. Каждому индивиду соответствуют два потенциальных исхода: $Y_i(1)$ – сон при наличии подписки;

$Y_i(0)$ – при ее отсутствии.

Индивидуальный эффект воздействия $\tau_i = Y_i(1) - Y_i(0)$.

Средний эффект воздействия:

$$ATE = \mathbb{E}[Y_i(1) - Y_i(0)] = \mathbb{E}[\tau_i].$$

ATE – это среднее по всей популяции изменение продолжительности сна, которое вызвало бы экзогенное появление подписки у случайно выбранного человека.

Локальный средний эффект воздействия (для тех, кто оформляет подписку именно благодаря промо оператора, $D_i(1) = 1$, $D_i(0) = 0$):

$$LATE = \mathbb{E}[Y_i(1) - Y_i(0) \mid D_i(1) > D_i(0)].$$

Классическое (Вальдовское) выражение без контрольных переменных:

$$LATE = \frac{\mathbb{E}[Y_i \mid Z_i = 1] - \mathbb{E}[Y_i \mid Z_i = 0]}{\mathbb{E}[D_i \mid Z_i = 1] - \mathbb{E}[D_i \mid Z_i = 0]}.$$

LATE отражает изменение сна только у тех людей, которые подписались бы при наличии промо и не подписались бы без него.

Задание 5.2. Используя симулированные, но недоступные в реальных данных потенциальные исходы, получите оценки среднего эффекта воздействия, условных средних эффектов воздействия и локального среднего эффекта воздействия. Для ATE и LATE результаты представьте в форме таблицы, а для CATE постройте гистограмму или ядерную оценку функции плотности. Проинтерпретируйте полученные значения.

Ответ.

Истинные значения ATE и LATE, представлены в таблице 28.

Таблица 28: Истинные значения ATE и LATE		
Эффект	Оценка	Комментарий
ATE	-0.1039	Средний эффект для всей популяции
LATE	-0.1064	Средний эффект для compliers

ATE составляет -0.1039 часа, то есть наличие стриминговой подписки сокращает продолжительность сна среднестатистического человека примерно на 6 минут. LATE составляет -0.1064 часа - незначительно отличается от ATE, что будет подробнее обсуждено в пункте 5.6.

Для идентификации типов агентов были восстановлены потенциальные исходы временной воздействия $D(Z=0)$ и $D(Z=1)$. Среди наблюдений выделяются четыре типа: compliers (26.1%) — те, кто берет подписку только при наличии промо-предложения оператора; always-takers (33.6%) — те, кто оформляет подписку вне зависимости от промо; never-takers (40.3%) — те, кто не отказывается от уже подключенного промо; defiers отсутствуют (0.0%), что подтверждает выполнение предположения о монотонности инструментальной переменной. Доля compliers в 26.1% является достаточно высокой, что свидетельствует о значимом влиянии промо-подписки на решение о приобретении стримингового сервиса.

Распределение индивидуальных эффектов воздействия представлено на рисунке 6, графике 1.




Рис. 6: Распределение индивидуальных эффектов воздействия

Распределение является двумодальным со смещением в отрицательную область: большинство индивидуальных эффектов отрицательны, однако существует заметная доля наблюдений с положительным эффектом, то есть для части населения наличие стриминговой подписки не сокращает, а увеличивает продолжительность сна. Это может объясняться тем, что некоторые люди используют стриминг как фоновый шум для засыпания.

Условные средние эффекты воздействия по подгруппам представлены на рисунке 6, графике 2. По признаку пола различия незначительны: эффект для мужчин (-0.1027 ч) и женщин (-0.1048 ч) практически совпадает с АТЕ, что соответствует процессу генерации данных, в котором пол не входит в формулу индивидуального эффекта τ_i . Более существенные различия наблюдаются по наличию детей: для людей без детей эффект заметно сильнее (-0.1162 ч), чем для родителей (-0.0683 ч). Это объясняется тем, что родители вынуждены спать меньше, независимо от времени просмотра стримингового контента, поэтому подписка меньше влияет на их режим сна. Наиболее выраженная гетерогенность наблюдается по хронотипу: для жаворонков эффект минимален (-0.0452 ч), тогда как для сов он почти в пять раз сильнее (-0.2394 ч). Собы и без того склонны ложиться поздно, а стриминговый контент дополнительно смещает их режим сна через эффект, что заложено в процессе генерации данных.

Условные средние эффекты по возрастным группам представлены на рисунке 7.




Рис. 7: Распределение условных средних эффектов по возрастным группам

Эффект относительно однороден по возрасту и близок к АТЕ для групп 16-25, 26-

35, 46-55 лет (около -0.10 ч). Наибольший по абсолютной величине эффект наблюдается в группе 36-45 лет (около -0.11 ч), что может объясняться совмещением высокой рабочей нагрузки с активным потреблением стримингового контента в вечернее время. Группа 56-70 лет демонстрирует наименьший эффект (около -0.09 ч), что согласуется с отрицательным коэффициентом при U_1 и меньшей долей сов среди людей старшего возраста.

Задание 5.3. Оцените средний эффект воздействия как разницу в средних по выборкам тех, кто получил и не получил воздействие. Опишите недостатки этого подхода с учетом специфики рассматриваемой вами экономической проблемы.

Ответ.

Наивная оценка среднего эффекта воздействия основана на непосредственном сравнении среднего числа часов сна у лиц, имеющих стриминг-подписку ($D=1$), и у лиц, ее не имеющих ($D=0$):

$$\hat{\tau}_{naive} = E[Y|D = 1] - E[Y|D = 0] = 6.178 - 6.538 = -0.361$$

Подписчики спят в среднем на 21.6 минуты меньше, чем неподписчики. Однако сравнение с истинным значением $ATE = -0.1039$ ч, полученным из потенциальных исходов в пункте 5.2, показывает, что наивный оценщик завышает по модулю негативный эффект подписки почти в 3.5 раза: смещение составляет -0.257 ч, или 247% от истинного ATE. Основная проблема наивного оценщика состоит в том, что он идентифицирует не только причинный эффект подписки, но и систематические различия в исходных характеристиках между подписчиками и неподписчиками. Классическая декомпозиция Хекмана позволяет разложить смещение на две составляющие:

$$\hat{\tau}_{naive} = \underbrace{ATE}_{\text{средний эффект по популяции}} + \underbrace{(E[Y_0 | D = 1] - E[Y_0 | D = 0])}_{\text{смещение отбора}} + \underbrace{(1 - p)(ATT - ATC)}_{\text{неоднородность эффекта}}$$

где $p = P(D = 1) = 0.439$. По данным симуляции: $ATE = -0.1039$, $ATT = -0.169$, $ATC = -0.053$, смещение отбора = -0.201 , а член неоднородности $(1 - p)(ATT - ATC) = 0.561 \cdot (-0.116) = -0.065$.

Даже в отсутствие подписки подписчики спали бы на 0.201 часа меньше неподписчиков - не из-за самой подписки, а из-за систематических различий в ненаблюдаемых характеристиках. Более подробный сравнительный анализ представлен в таблице 29

Таблица 29: Сравнение характеристик подписчиков и неподписчиков

Переменная	D=1	D=0	Разность
Хронотип «сова» (U_1 , доля)	0.374	0.246	0.128
Самоконтроль (U_2 , среднее)	2.744	4.059	-1.315
Возраст (X_1)	33.500	37.229	-3.729
Доход (X_6)	27476.140	26657.098	819.042

Среди подписчиков доля лиц с вечерним хронотипом («сов», $U_1 = 1$ равна 0.374 против 0.246 среди неподписчиков. «Совы» в среднем спят меньше вне зависимости от наличия подписки (корреляция U_1 и $Y = -0.234$), но при этом они склонны оформлять подписку чаще (корреляция U_1 и $D = 0.138$). Это создает ложную отрицательную связь: наивный оценщик частично «видит» не вред подписки, а биологическую особенность целевой аудитории сервисов.

Еще более выраженный канал смещения - самоконтроль (U_2). Подписчики демонстрируют

в среднем почти вдвое более низкий уровень самоконтроля (2.74 против 4.06 баллов). Поскольку самоконтроль положительно связан со сном (корреляция 0.498) и отрицательно с вероятностью оформить подписку (корреляция -0.324), неконтролируемый U_2 систематически занижает средний сон в группе подписчиков.

Также, подписчики в среднем моложе на 3.7 года (33.5 против 37.2 лет). Молодые люди в среднем спят меньше в выборке (коэффициент при возрасте в уравнении Y отрицательный), что дополнительно усугубляет смещение. Таким образом, наивный оценщик в данном случае не позволяет разграничить эффект самой подписки и систематическое отличие образа жизни ее типичного пользователя.

Задание 5.4. Используя оценки, полученные лучшими из обученных ранее классификационных и регрессионных моделей, оцените средний эффект воздействия с помощью:

- метода наименьших квадратов.
- условных математических ожиданий.
- взвешивания на обратные вероятности.
- метода двойной устойчивости.
- двойного машинного обучения.

Сравните результаты и назовите ключевую предпосылку этих методов. Содержательно обсудите причины, по которым она может соблюдаться или нарушаться в вашем случае. Приведите содержательную экономическую интерпретацию оценки среднего эффекта воздействия.

Повышенная сложность: включите дополнительный метод, не рассматривавшийся в курсе, и опишите его принцип работы, преимущества и недостатки по сравнению с другими методами.

Ответ.

Для оценки среднего эффекта воздействия используются лучшие модели из разделов 3 и 4: случайный лес в качестве классификатора для оценки вероятности наличия подписки $\hat{e}(X) = \hat{P}(D = 1 | X)$ и градиентный бустинг в качестве регрессионной модели для оценки условных ожиданий $\hat{\mu}_1(X) = \hat{E}[Y | D = 1, X]$ и $\hat{\mu}_0(X) = \hat{E}[Y | D = 0, X]$. Оценки вероятности $\hat{e}(X)$ находятся в диапазоне $[0.136, 0.800]$, что подтверждает выполнение условия перекрытия и корректность применения всех пяти методов. Результаты представлены в Таблице 30.

Таблица 30: Оценки среднего эффекта воздействия (ATE)			
Метод	Оценка ATE	SE	Истинный ATE
МНК (OLS)	-0.4101	0.0142	-0.1039
Условные ожидания	-0.3479	—	-0.1039
IPW	-0.2758	—	-0.1039
Doubly Robust	-0.4020	—	-0.1039
Double ML	-0.4062	0.0153	-0.1039

Все пять методов дают оценки ATE в диапазоне от -0.2758 до -0.4101, что существенно превышает по абсолютной величине истинное значение $\widehat{ATE} = -0.1039$. Ключевой предпосылкой всех пяти методов является условная независимость потенциальных исходов от

воздействия при заданных контрольных переменных X :

$$(Y_0, Y_1) \perp D \mid X, \quad 0 < e(X) < 1. \quad (1)$$

В рассматриваемом случае данная предпосылка заведомо нарушена: в процессе генерации данных отбор в группу подписчиков зависит от ненаблюдаемых переменных U_1 (хроно-тип) и U_2 (самоконтроль сна), которые одновременно влияют и на продолжительность сна Y . События ($U_1 = 1$) чаще оформляют подписку и при этом меньше спят по независимым причинам, что создает отрицательную ковариацию между D и Y через ненаблюдаемый канал. Именно поэтому все методы переоценивают отрицательный эффект подписки.

Важно различать два независимых источника отклонения оценок. Общий сдвиг всех пяти методов от истинного АТЕ (-0.1039) в сторону $-0.3 \dots -0.4$ вызван нарушением условной независимости: ненаблюдаемый конфаундинг через U_1 и U_2 одинаково смещает все наблюдательные оценщики, поскольку ни один из них не контролирует U_1 и U_2 . Разброс же между самими методами (от -0.2758 до -0.4101) с этим конфаундингом не связан - при $n = 5000$ все пять методов таргетируют один и тот же наблюдательный параметр (АТЕ при контроле только X) и при корректно специфицированных вспомогательных моделях должны давать близкие значения. Наблюдаемое расхождение отражает качество и калибровку nuisance-моделей: оценка склонности $\hat{e}(X)$ на основе случайного леса плохо откалибрована ($AUC \approx 0.67$, вероятности концентрируются вблизи базовой доли, как показано в пункте 3.6), из-за чего обратные веса в IPW становятся нестабильными, а оценки разных методов по-разному реагируют на эту неточность.

Метод МНК дает наиболее смещенную оценку (-0.4101): он включает D как регрессор напрямую и полностью приписывает корреляцию между подпиской и плохим сном причинному эффекту, не делая никакой поправки на селективность отбора. Метод условных математических ожиданий дает оценку -0.3479 , она менее смещенная, поскольку гибкая регрессионная модель частично улавливает нелинейные зависимости между X и Y . Метод IPW (-0.2758) является наименее смещенным среди всех: взвешивание на обратные вероятности частично корректирует различия в наблюдаемых характеристиках между группами. Doubly Robust (-0.4020) и Double ML (-0.4062) дают оценки, близкие к МНК. Это согласуется с теорией: двойная устойчивость защищает от неверной спецификации одной из двух вспомогательных моделей, но не от нарушения предпосылки об игнорируемости отбора вследствие ненаблюдаемого конфаундинга. При наличии пропущенных переменных ни один из пяти методов не способен восстановить истинный причинный эффект, для этого необходимо использовать инструментальную переменную.

Задание 5.5. Оцените условные средние эффекты воздействия с помощью:

- метода наименьших квадратов
- S-learner
- T-learner
- метода трансформации классов
- X-learner

Сравните результаты и обсудите, насколько в вашем случае мотивированы применения X-learner. Опишите, как можно было бы использовать полученные вами оценки в бизнесе или при реализации государственных программ. **Повышенная сложность:** включите дополнительный метод, не рассматривавшийся в курсе.

Ответ.

Результаты оценки условных средних эффектов воздействия пятью методами представлены в Таблице 31.

Таблица 31: Оценки условных средних эффектов воздействия (CATE)

Метод	Средний CATE	Ст. откл.	Корр. с истинным τ_i
МНК (OLS)	−0.4108	0.0481	0.112
S-learner	−0.3479	0.0693	0.104
T-learner	−0.4035	0.1183	0.080
Трансф. классов	−0.2758	1.2437	−0.081
X-learner	−0.4071	0.0706	0.102

Все пять методов дают средние CATE в диапазоне от −0.2758 до −0.4108, что, как и в пункте 5.4, существенно превышает по абсолютной величине истинный ATE = −0.1039. Смещение обусловлено теми же причинами: нарушением предпосылки *unconfoundedness* вследствие ненаблюдаемого конфаундинга через U_1 и U_2 .

Наиболее важным показателем качества оценок CATE является корреляция с истинным индивидуальным эффектом τ_i , поскольку она отражает способность метода улавливать гетерогенность эффекта, а не только его среднее значение. Все методы демонстрируют крайне низкую корреляцию с истинным τ_i : от −0.081 (метод трансформации классов) до 0.112 (МНК). Это объясняется тем, что истинная гетерогенность эффекта определяется прежде всего ненаблюдаемой переменной U_1 (хронотип): совы теряют значительно больше сна (−0.2394 ч) по сравнению с жаворонками (−0.0452 ч). Поскольку U_1 недоступна наблюдателю, ни один из методов не способен восстановить эту гетерогенность по наблюдаемым признакам X .

Метод трансформации классов выделяется аномально высоким стандартным отклонением оценок (1.2437) и отрицательной корреляцией с истинным τ_i (−0.081). Это связано с тем, что модифицированный исход $Y^* = Y(D - \hat{e}(X))/(\hat{e}(X)(1 - \hat{e}(X)))$ крайне чувствителен к значениям $\hat{e}(X)$, близким к 0 или 1: даже при выполненном условии перекрытия значения $\hat{e}(X) \in [0.136, 0.800]$ приводят к усилению шума при делении, что делает индивидуальные оценки нестабильными.

Применение X-learner в данном случае слабо мотивировано. X-learner разрабатывался для ситуаций с существенным дисбалансом групп воздействия, когда одна из групп значительно меньше другой и T-learner дает ненадежные оценки для малочисленной группы. В нашем случае доля подписчиков составляет $D = 1$: 43.9%, что близко к балансу, поэтому выигрыш X-learner над T-learner оказывается незначительным: корреляция с истинным τ_i составляет 0.102 против 0.080 у T-learner, а средние CATE практически совпадают (−0.4071 и −0.4035 соответственно).

Несмотря на смещенность оценок уровня CATE, относительная гетерогенность, может быть использована в прикладных целях. Государство, реализующее профилактическую программу охраны здоровья сна, может применять оценки CATE для *таргетирования* (uplift-моделирования): направлять профилактические материалы прежде всего тем гражданам, для которых предсказанный эффект воздействия наибольший по абсолютной величине.

Задание 5.6. Оцените локальный средний эффект воздействия с помощью:

- двойного машинного обучения без инструментальной переменной
- двойного машинного обучения с инструментальной переменной.

Сопоставьте результаты и объясните, в чем в вашем случае будет заключаться различие между средним и локальным средним эффектами воздействия. Приведите содержательную экономическую интерпретацию оценки локального среднего эффекта воздействия.

Повышенная сложность: воспользуйтесь параметрической моделью, например, пакетом `switchSelection`. Обсудите ее преимущества и недостатки такого по сравнению с двойным машинным обучением. Обычный метод инструментальных переменных параметрическим подходом не считается.

Ответ.

Результаты приведены ниже в таблице 32. Двойное машинное обучение без инструмента дает -0.397 , то есть практически то же смещенное значение уровня АТЕ. Это подтверждает, что обычный контроль наблюдаемых переменных X не позволяет полностью решить проблему эндогенности. Двойное машинное обучение с инструментом дает оценку в -0.084 при стандартной ошибке 0.057 . Приближенный доверительный интервал $[-0.195; 0.027]$ покрывает истинное значение LATE -0.106 , значит, инструментальная оценка состоятельна и является единственным методом на наблюдаемых данных, который восстанавливает истину.

Таблица 32: Оценки локального среднего эффекта воздействия (LATE)

Метод	Оценка	SE
DML без инструмента	-0.3972	—
DML с инструментом	-0.0840	0.0569
Control function (бонус)	-0.0581	—

Инструмент (промо-подписка оператора связи) сдвигает вероятность оформления подписки, не влияя на сон напрямую, поэтому выполнены условие релевантности ($P(D = 1 | Z = 1)$ заметно выше $P(D = 1 | Z = 0)$) и условие валидности. Полученная методом контрольной функции параметрическая оценка (-0.058) близка к предыдущим результатам. Она также устраняет смещение из-за эндогенности, пусть и уступает им по абсолютной величине. Она опирается на более сильные предпосылки (такие как совместная нормальность ошибок и функциональная форма). Это и объясняет расхождение с полупараметрической оценкой, полученной с помощью метода двойного машинного обучения (DML).

Рассмотрим различия между LATE и АТЕ. LATE это эффект для тех, кто оформляет подписку именно из-за промо (таких людей называют "комплаенсеры" и они составляют около 26% выборки), тогда как АТЕ усредняет эффект по всей совокупности. Идейно эти величины различны, так как эффект зависит от U_1 , а комплаенсеры это отобранная подгруппа. Однако численно они оказались довольно близки (-0.106 против -0.104), потому что в данном исследовании поведение комплаенсеров не является специфическим или аномальным по U_1 . Но довольно важно, что в условиях эндогенности именно инструментальный подход позволяет идентифицировать истинный эффект на основе наблюдаемых данных. Экономическое объяснение получается следующим: для лиц, чье решение о подписке определялось промо-предложением, ее оформление снижает продолжительность сна примерно на 5–6 минут в день, что указывает на небольшой, но ненулевой эффект.

Задание 5.7. Оцените средние и локальные средние эффекты воздействия, используя худшие из обученных классификационной и регрессионной моделей. Сопоставьте результаты с полученными на лучших моделях и сделайте вывод об устойчивости результатов к качеству используемых методов машинного обучения.

Ответ.

Сопоставление лучших и худших вспомогательных моделей приведено в таблице 33. Оценки практически совпадают: ATE равен -0.4062 против -0.408 , LATE равен -0.084 против -0.081 .

Таблица 33: Устойчивость оценок к качеству вспомогательных моделей

Оценка	Лучшие модели	Худшие модели	Истинное
ATE (DML)	-0.4062	-0.408	-0.1039
LATE (DML-IV)	-0.0840	-0.081	-0.1064

Эта нечувствительность является следствием ортогональности по Нейману целевой функции двойного машинного обучения. Благодаря занулению производной в истинной точке, смещения первого порядка из предварительных уравнений не искажают финальный результат. Это позволяет итоговой оценке сохранять стандартную состоятельность при росте числа наблюдений, невзирая на более медленную сходимость базовых алгоритмов, и делает ее независимой от смены методов машинного обучения.

Остаточное смещение ATE объясняется структурной причиной, то есть нарушением условия условной независимости. Улучшение прогнозных моделей не устранило бы это смещение; его устраняет только наличие корректного инструмента. Следует оговориться, что в данном прогоне и лучшая, и худшая по выбранному критерию вспомогательные модели свелись к одному семейству, поэтому контраст между ними невелик. Для более наглядной проверки устойчивости имеет смысл сопоставить заведомо разные алгоритмы, например градиентный бустинг и линейную модель.

Задание 5.8 и 5.9. Резюмируйте ключевые выводы проведенного в данном разделе анализа. В случае необходимости проведите дополнительный анализ.

Ответ.

Сводная таблица всех оценок (таблица 34) и сравнительный график (рисунок 8) обобщают результаты. Наивная разность средних и все наблюдательные оценки ATE завышают отрицательный эффект примерно вчетверо из-за отбора на ненаблюдаемых факторах. Только инструментальное двойное машинное обучение и параметрическая контрольная функция дают значения, близкие к истинному LATE.

Таблица 34: Сводное сравнение всех оценок эффекта

Оценка	Значение
Истинный ATE	-0.1039
Истинный LATE	-0.1064
Наивная разность	-0.3606
OLS	-0.4101
Условные ожидания	-0.3479
IPW	-0.2758
Doubly Robust	-0.4020
DML (ATE)	-0.4062
DML без инструмента	-0.3972
DML с инструментом (LATE)	-0.0840
Control function	-0.0581

Левая панель рисунка 8 показывает, что распределения склонности для подписчиков и неподписчиков существенно перекрываются на отрезке примерно от 0.15 до 0.8 без массы на границах, поэтому условие перекрытия выполнено и методы перевзвешивания не




Рис. 8: Слева: перекрытие оценок склонности для групп $D = 1$ и $D = 0$.
Справа: сравнение всех оценок эффекта с истинными значениями ATE и LATE.

управляются экстремальными весами. Правая панель наглядно демонстрирует, что все наблюдательные оценки группируются около -0.4 и далеки от истинной линии -0.10 , тогда как инструментальная оценка DML и контрольная функция расположены рядом с истинным значением.

Подводя итог, стоит отметить, что при эндогенном воздействии и наличии ненаблюдаемого конфаундинга сложность этапа машинного обучения не заменяет идентификацию. Все наблюдательные методы, сколь угодно гибкие и корректно реализованные, наследуют смещение пропущенной переменной и согласованно дают неверный ответ. Состоятельную оценку обеспечивает только корректный инструмент, и в данном случае идентифицируется локальный средний эффект для комплаенсеров. Полученные результаты следует трактовать с учетом ограничений: они основаны на одной реализации конкретного процесса генерации данных, а близость LATE и ATE специфична для выбранной структуры зависимостей и не является общим свойством. Тем не менее качественная картина, то есть смещение наблюдательных методов и состоятельность инструментального подхода, устойчива и согласуется с теорией причинного вывода.

Список литературы

- [1] Alfonsi, V., Varallo, G., Scarpelli, S., Gorgoni, M., Filosa, M., De Gennaro, L., Musetti, A., & Franceschini, C. (2023). ‘This is the last episode’: The association between problematic binge-watching and loneliness, emotion regulation, and sleep-related factors in poor sleepers. *Journal of Sleep Research*, 32(1), e13747. <https://doi.org/10.1111/jsr.13747>
- [2] Exelmans, L., & Van den Bulck, J. (2017). Binge viewing, sleep, and the role of pre-sleep arousal. *Journal of Clinical Sleep Medicine*, 13(8), 1001–1008. <https://doi.org/10.5664/jcsm.6704>
- [3] Kroese, F. M., De Ridder, D. T. D., Evers, C., & Adriaanse, M. A. (2014). Bedtime procrastination: Introducing a new area of procrastination. *Frontiers in Psychology*, 5, 611. <https://doi.org/10.3389/fpsyg.2014.00611>

- [4] Lok, R., Qian, J., & Chellappa, S. L. (2024). Sex differences in sleep, circadian rhythms, and metabolism: Implications for precision medicine. *Sleep Medicine Reviews*, 75, 101926. <https://doi.org/10.1016/j.smr.2024.101926>
- [5] Redeker, N. S., Caruso, C. C., Hashmi, S. D., Mullington, J. M., Grandner, M., & Morgenthaler, T. I. (2019). Workplace interventions to promote sleep health and an alert, healthy workforce. *Journal of Clinical Sleep Medicine*, 15(4), 649–657. <https://doi.org/10.5664/jcsm.7734>
- [6] Seki, T., Shimura, A., Nakajima, K., et al. (2026). Deviation from optimal physical activity duration worsens depressive symptoms through high sleep reactivity and poor sleep quality in adult volunteers from the community. *European Journal of Sport Science*, e70111. <https://doi.org/10.1002/ejsc.70111>
- [7] Zhong, C., Masters, M., Donzella, S. M., Diver, W. R., & Patel, A. V. (2025). Electronic screen use and sleep duration and timing in adults. *JAMA Network Open*, 8(3), e252493. <https://doi.org/10.1001/jamanetworkopen.2025.2493>